1. Dataset

1.1. Training dataset

Dataset	Dữ liệu cung cấp và vai trò
HOI4D	Video tương tác người–vật trong môi trường thực; có nhãn liên quan đến vật thể chuyển động.
Dynamic Replica	Cảnh tổng hợp có chuyển động camera và vật thể, hỗ trợ học hình học và chuyển động.
YouTubeVOS2018-motion	Video có vật thể nổi bật và mask phân đoạn, được xử lý để phục vụ bài toán chuyển động.
OmniWorld-motion	9 chuỗi video dài, mỗi chuỗi khoảng 2.000–10.000 frame.
GOT-Motion	130 video ngắn được chọn từ GOT-10K, có bổ sung nhãn mask chuyển động.

Dataset	Loại dữ liệu	Đặc điểm chính	Vai trò trong huấn luyện
HOI4D	Video thực tế RGB-D	Người tương tác với đồ vật, có thông tin hình học 3D	Học chuyển động trong các tình huống tương tác người–vật
Dynamic Replica	Video cảnh tổng hợp	Stereo, depth, camera pose, optical flow và mask	Bổ sung thông tin hình học và chuyển động của cảnh
YouTubeVOS2018-motion	Video thực tế	Video đa dạng, có object masks theo frame	Bổ sung dữ liệu phân đoạn đối tượng; cần lưu ý mask gốc không nhất thiết là motion mask
OmniWorld-motion	Video cảnh tổng hợp	9 chuỗi video dài, khoảng 2.000–10.000 frame mỗi chuỗi theo mô tả paper	Tăng độ đa dạng và độ dài của chuỗi chuyển động
GOT-Motion	Video thực tế	130 video ngắn, phát triển từ GOT-10k và có bổ sung nhãn mask chuyển động	Học phân biệt vùng chuyển động trong các cảnh thực tế

1.2. Evaluation Dataset

Dataset	Link chính thức	Mục đích
DAVIS 2016	Tải dữ liệu và code	Video có đối tượng được gán mask dày đặc theo frame.
DAVIS 2017	Trang DAVIS	Đánh giá với nhiều đối tượng trong một video.
FBMS-59	Tải dữ liệu và evaluation code	Benchmark chuyên về phân đoạn vật thể chuyển động; có tập train/test.
SegTrackV2	Paper và thông tin dataset	Video ngắn với các đối tượng biến dạng, chuyển động và che khuất.

2. Abstract

Motion segmentation in dynamic scenes is challenging

- conventional methods heavily rely on estimating (ước lượng) camera poses and point correspondences

Các phương pháp suy luận thống kê hoặc tối ưu hóa lặp hiện có gặp khó khăn trong việc hạn chế sai số tích lũy qua nhiều giai đoạn xử lý, dẫn đến hiệu suất còn hạn chế hoặc chi phí tính toán cao. pháp hoàn toàn dựa trên học máy, trực tiếp suy luận các vật thể chuyển động từ những biểu diễn đặc trưng tiềm ẩn thông qua các cơ chế attention, qua đó cho phép thực hiện phân đoạn chuyển động theo kiểu truyền thẳng (feed-forward) từ đầu đến cuối.

Our key insight is to bypass explicit correspondence estimation and instead let the model learn to implicitly disentangle object and camera motion . (Thay vì dự đoán , ước lượng tường minh các điểm tương ứng, nên để cho model tự học cách phân biệt vật thể và chuyển động của camera một cách ngầm định)

Được hỗ trợ bởi những tiến bộ gần đây trong tái tạo hình học cảnh 4D (ví dụ: π^3), phương pháp đề xuất tận dụng tư thế camera đáng tin cậy và các thông tin tiên nghiệm phong phú về không gian–thời gian, giúp quá trình huấn luyện ổn định và suy luận mạnh mẽ

2. introduction

Motion segmentation nhằm tách biệt chuyển động của các vật thể với chuyển động do camera gây ra trong các chuỗi video.

- Camera-induced motion: chuyển động xuất hiện trên hình ảnh do camera di chuyển. Ví dụ khi camera quay sang phải, những cái cây đứng yên vẫn có hiện tượng dịch trái trên khung hình .

Vấn đề

- Các mô hình truyền thống dựa trên tín hiệu chuyển động 2D như optical flow gặp khó khăn trong việc phân biệt chuyển động độc lập của vật thể với chuyển động của camera do thiếu thông tin về độ sâu .
- Hơn nữa, khả năng nhận thức theo thời gian ngắn của optial flow khiến cá mô hình nhạy cảm với hiện tượng che khuất và không thể đáp ứng tốt đối với các yêu cầu phân tích chuyển động dài hạn

Các phương pháp đã được xử lý

Để giải quyết những vấn đề này, các nhà nghiên cứu đã nổ lực khai thác thông tin về độ sâu 3D và các phương pháp tối ưu hóa lặp nhằm tăng độ vững chắc trong điều kiện camera chuyển động không ràng buộc

- ROMO: kết hợp tường minh optical flow với các tín hiệu hình học epipolar để tách biệt chuyển động của vật thể khỏi chuyển động của camera, đồng thời sử dụng quá trình tối ưu hóa lặp trên từng cảnh để tinh chỉnh camera pose và mask refinement (mặt nạ phân đoạn)
- MegaSaM: áp dụng một khung SLAM visual deep để ước lượng các tham số camera và độ sâu từ video đơn mắt có chứa các vật thể chuyển động.
- SAM2: Đề xuất kết hợp các tín hiệu chuyển dộng từ quỹ đạo dài hạn, cho phép làm dày mặt nạ ở mức độ pixel thông prompt và lặp đi lặp lại.

Phương pháp	Ý tưởng chính
RoMo	Kết hợp optical flow với hình học epipolar, sau đó tối ưu lặp tư thế camera và mặt nạ.
MegaSaM	Sử dụng khung SLAM thị giác để ước lượng tư thế camera và độ sâu từ video đơn mắt.
Huang et al.	Kết hợp thông tin quỹ đạo chuyển động dài hạn với SAM2 để hoàn thiện mặt nạ ở cấp pixel.

Một vài thuật ngữ cần nhớ:

- *Epipolar cues*: các ràng buộc hình học giữa hai góc nhìn, giúp mô tả chuyển động hình ảnh liên quan đến camera.
- *Point correspondences:* các điểm được xác định là tương ứng với nhau giữa những khung hình khác nhau.
- *Pose refinement*: tinh chỉnh tư thế camera, thường gồm vị trí và hướng của camera.
- *Mask refinement:* cải thiện mặt nạ phân đoạn để xác định chính xác hơn vùng vật thể chuyển

động.

Các hạn chế

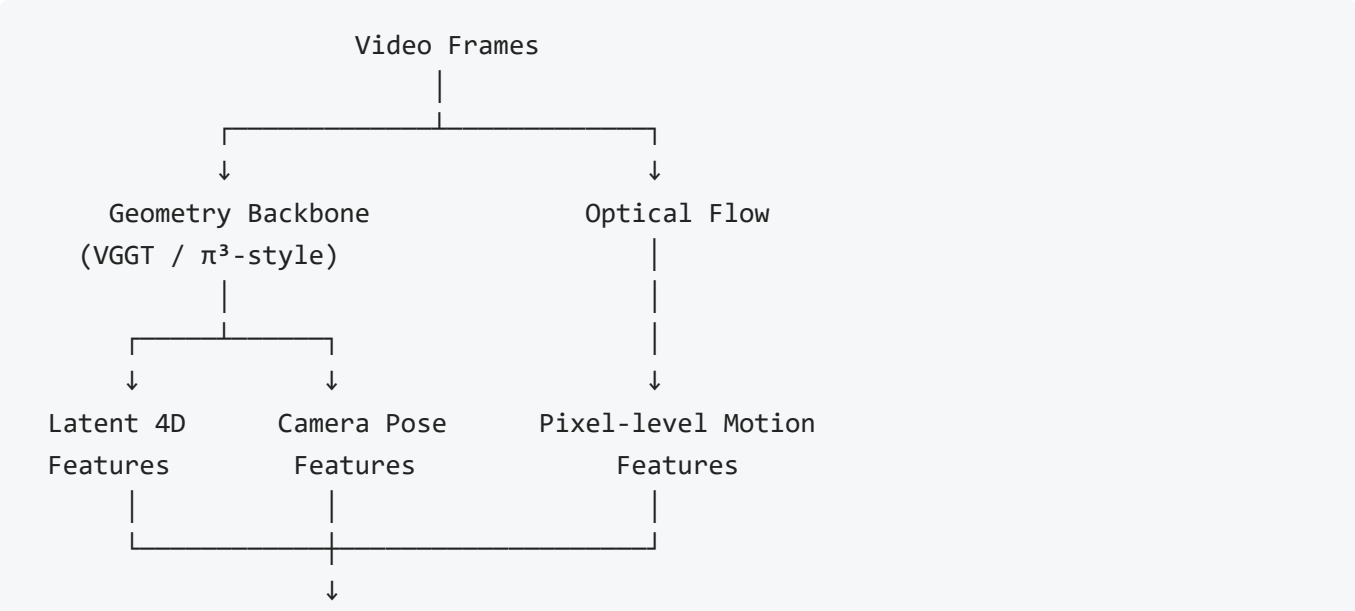
- Phụ thuộc nhiều vào các biểu diễn trung gian dễ nhiễu. Những tín hiệu được tính toán trước như *optical flow, point correspondences hay epipolar constraint* thường không đáng tin cậy trong những cảnh động và dẫn đến sự tích lũy sai số xuyên suốt quy trình nhiều giai đoạn
- Tối ưu hóa lặp có chi phí tính toán cao. Để hạn chế tích lũy sai số , các kỹ thuật tối ưu hóa lặp như *iterative pose refinement*, *mask optimization*, *point tracking* thường được sử dụng. Điều này làm tăng đáng kể chi phí suy luận và khiến các mô hình khó mở rộng để ứng dụng trong thế giới thực.

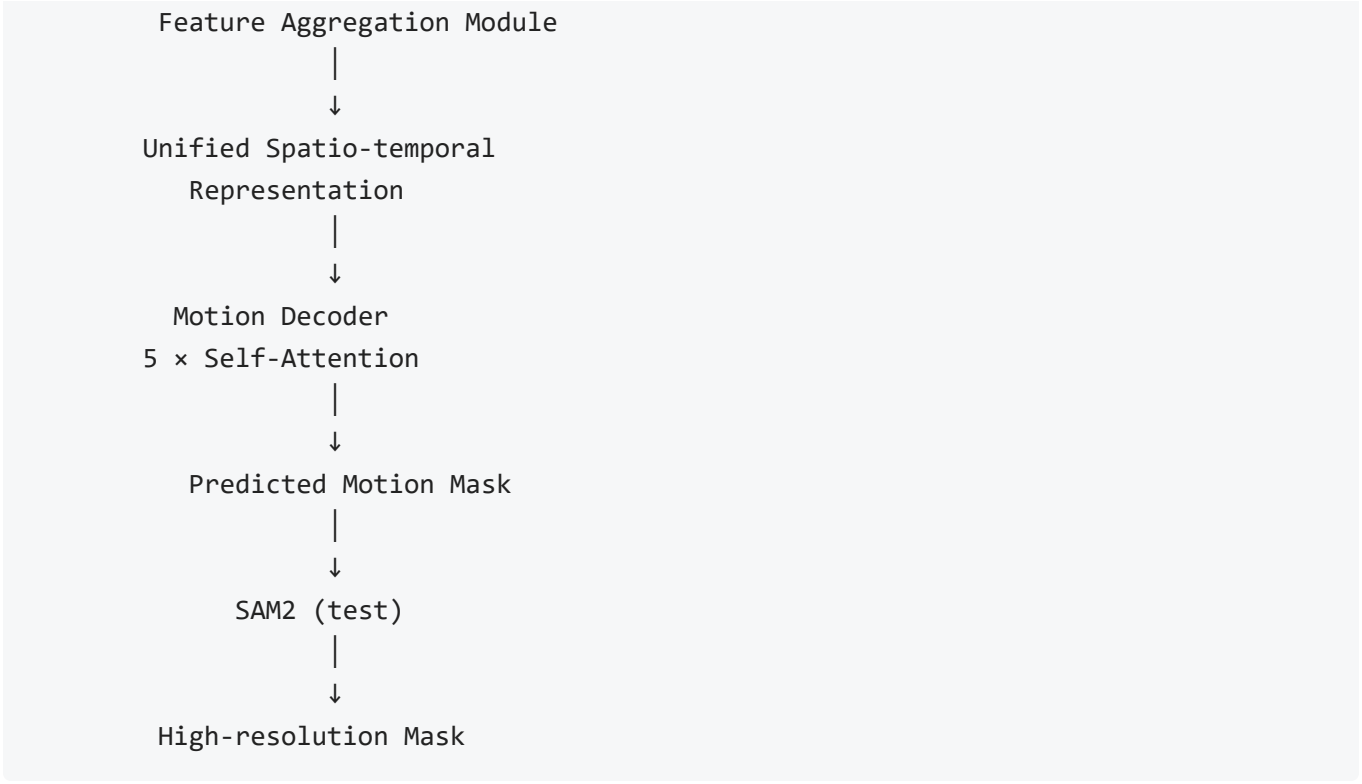
Chúng tôi chứng minh rằng, lần đầu tiên, một mô hình feed-forward đơn giản và hiệu quả hơn đáng kể có thể đạt được hiệu suất tương đương, thậm chí tốt hơn, so với các phương pháp dựa trên tối ưu hóa lặp.

Các mô hình tái tạo theo cơ chế feed-forward resconstrustor

- *VGGT* và *DUSt3R* đều cho phép ước lượng đáng tin cậy hình học 3D và các tham số từ camera ảnh
- *Easi3R* khai thác các bản đồ attention bên trong DUSt3R để tách nội dung động khỏi nội dung tĩnh phục vụ cho bài toán tái tạo 4D, đồng thời loại bỏ nhu cầu phải fine-tune mạng
- *pi3* dự đoán *affine-invariant camera pose* và *scale - invariant pointmaps* (pointmap bất biến theo tỷ lệ) mà không cần một hệ tọa độ toàn cục
  Những công trình này đã được pre-trained chứa thông tin hữu ích, có nhận thức về camera chuyển động. Vì vậy. thách thức được thu gọn thành việc học cách giải mã những biểu diễn này một cách hiệu quả để phục vụ cho bài toán motion segmentation

Framework đề xuất





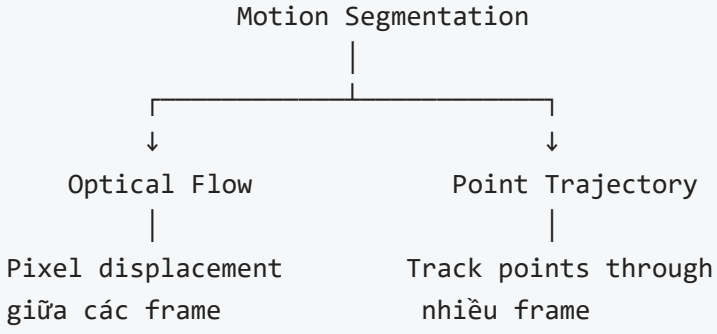
Framework thiết kế gồm 2 module:

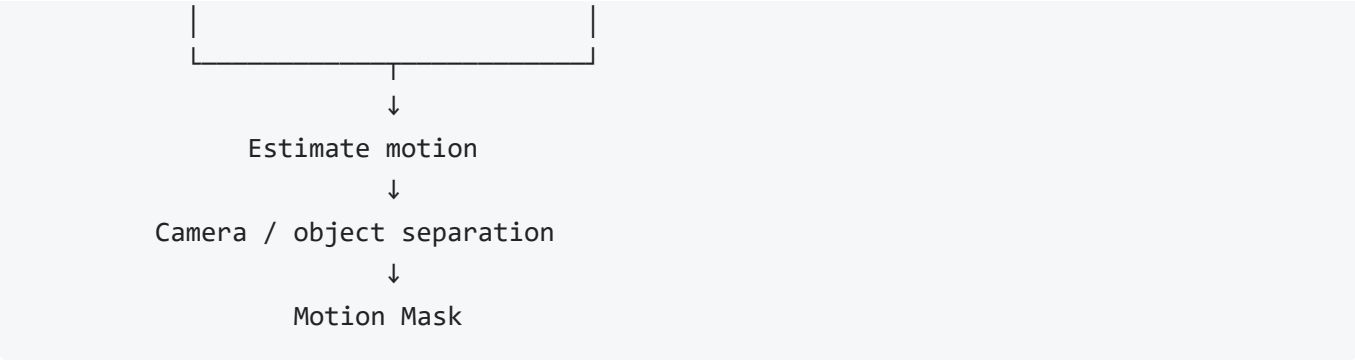
- Feature aggregation module (module tổng hợp đặc trưng): Tích hợp nhiều đặc trưng
  - latent 4D features
  - Camera pose from 4D geometry priors
  - pixel-level motion in the optical flow
- Motion decoder module : cấu trúc khá đơn giản , chỉ gồm 5 lớp self-attention

3. Related work

3.1. Conventional Motion Segmentation

Các phương pháp phổ biến hiện nay chủ yếu dựa vào việc estimate camera pose và point correspondences.Mặc dù những tín hiệu này mang nhiều thông tin nhưng trong môi trường hạn chế, chúng dễ bị nhiễu và thiếu ổn định trong những tìn huống khó như các bề mặt ít hoặc không có texture , hiện tượng che khuất hay chuyển động camera lớn.





3.2. Feed forward 4D Reconstrcution

4D scene reconstruction tập trung vào việc khôi phục hình học 3D của cảnh sao cho nhất quán theo thời gian, cùng với camera pose from dynamic video input.
Các phương pháp:

- *MonS3R* và *C4D* sử dụng hướng tiếp cận dựa trên tối ưu hóa để đồng thời tối ưu độ sâu, chuyển động và camera pose thông qua iterative refinement. Mặc dù đạt độ chính xác đáng chú ý, những phương pháp này có chi phí tính toán cao và khả năng mở rộng hạn chế đối với các ứng dụng thực tế.
- *DUSt3R* giới thiệu kiến trúc Transformer để tái tạo ảnh 3D theo từng cặp ảnh trong các cảnh tĩnh. *CUT3R* tiếp tục mở rộng hướng tiếp cận này bằng một thiết kế hồi quy có trạng thái, trong khi *TTT3R* nghiên cứu các chiến lược test-time training nhằm tăng khả năng tổng quát hóa trên các chuỗi cảnh.
- *PAGE-4D* mở rộng hướng tiếp cận này sang các cảnh động thông qua một soft dynamics-aware masks dùng để điều chỉnh attention phục vụ dự đoán tư camera pose và hình học 3D. Tuy nhiên thiết kế sử dụng một mask của nó hạn chế khả năng mô hình hóa chuyển dộng ở mức chi tiết.
- *Easi3R* tập trung vào việc trích xuất các tín hiệu chuyển động từ mô hình dành cho cãnh tĩnh mà không cần huấn luyện thêm , nhưng hoạt động theo kiểu hậu xử lý và thiếu sự tích hợp end-to-end.
- VGGT4D [9] mở rộng triết lý của Easi3R sang backbone VGGT [37], còn MUT3R [35] tiếp tục điều chỉnh các ý tưởng tương tự cho CUT3R. Cả hai phương pháp đều trích xuất các tín hiệu động từ những foundation model vốn ban đầu được thiết kế cho tái tạo cảnh tĩnh, thay vì mô hình hóa một cách tường minh cấu trúc của cảnh động
- 8] cho phép dự đoán điểm dày đặc và được căn chỉnh theo thời gian dưới sự giám sát động, nhưng chỉ hoạt động trên các cặp góc nhìn cố định và không thực hiện ước lượng tư thế camera.

Trong số các phương pháp feed-forward π^3 nổi bật với khả năng tổng quát đồng thời dự đoán camera pose per frame , dense point không phụ thuộc các tham chiếu cố định.

- Việc kết hợp giữa *permutation-equivariant attention* cùng với self attention luân phiên giữa góc nhìn và toàn cục giúp tạo ra hình học nhất quán theo thời gian, đồng thời mã hóa các đặc trưng giàu thông tin về chuyển động.
- Việc mô hình hóa tường minh camera pose và 4D geometry cung cấp những thông tin hữu ích cho bài toán chuyển động.

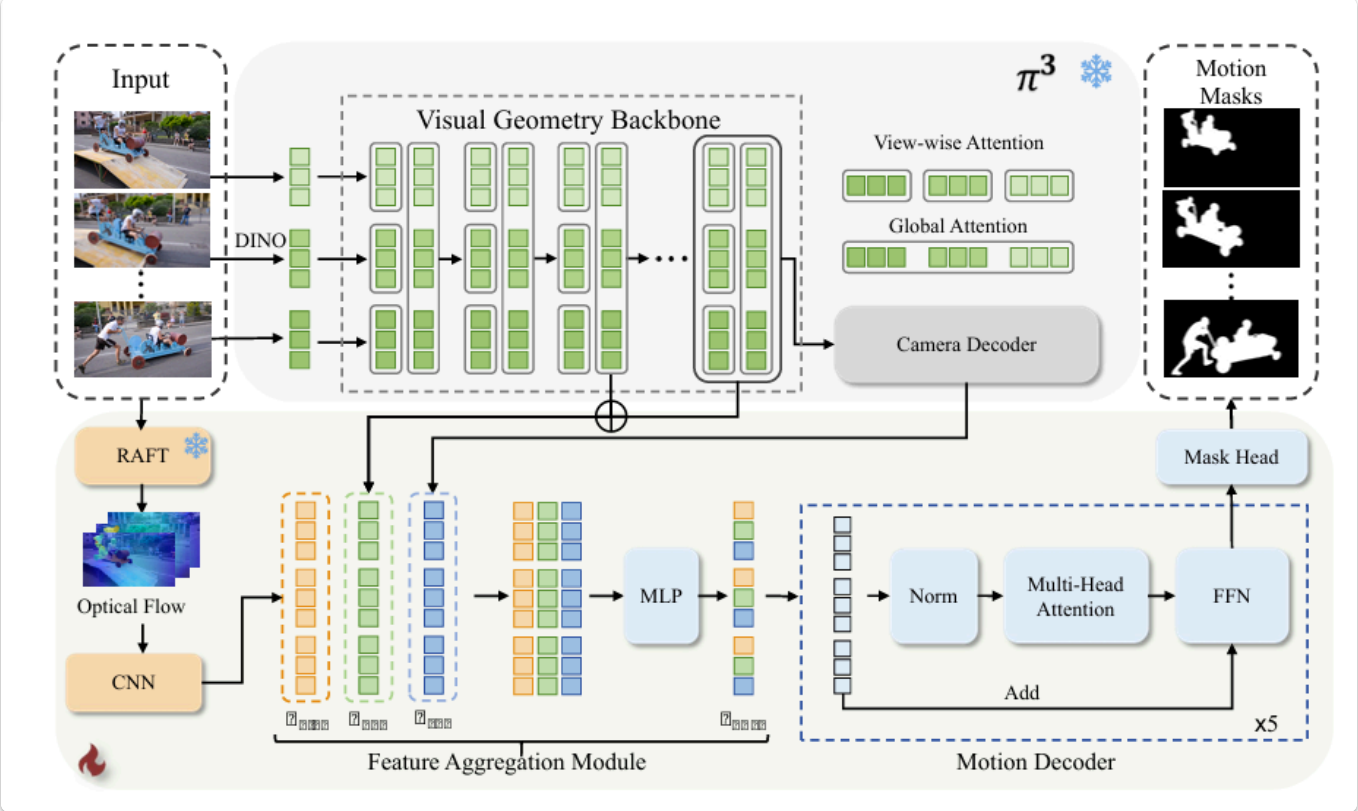
4. Method

Paper giải quyết bài toán motion segmentation bằng cách thay đổi căn bản xây dựng bài toán: Trực tiếp học thông tin chuyển động từ các biểu diễn hình học, qua đó tránh sự tích lũy sai số từ các estimate trung gian không hoàn hảo cũng như quá trình tối ưu hóa lặp tốn kém về mặt tính toán.

4.1. Feed-forward Architecture

- Optical flow cung cấp thông tin chuyển động ở mức pixel, có thể được xem là một tín hiệu tổng hợp bao gồm cả sự camera pose và dynamic object motion
- 4D reconstruction model π^3 có khả năng tạo ra các đầu ra hình học như *point cloud* và camera pose. Do đó , các tầng đặc trưng bên trong mô hình này vốn đã encode những prior phong phú về cấu trúc ảnh , 3D geometry , camerapose
- Bằng cách tích hợp các dạng đặc trưng này, mô hình xây dựng một biểu diễn đặc trưng không - thời gian thống nhất, kết hợp chuyển động cục bộ của pixel và hình học toàn cục của cảnh và động học camera . Nhờ đó có thể trực tiếp giải mã các vật thể chuyển động mà không cần thực hiện explicit correspondence matching hay iterative optimization

Họ lấy chính xác **4 layer: 5, 15, 35, 36** của 36-layer Visual Geometry Backbone



Module feature aggregation sau đó kết hợp ba loai feature này thông qua MLP

$$F_{\text{fuse}} = MLP([F_{\text{geo}}; F_{\text{flow}}; F_{\text{cam}}]).$$

Moule motion decoder chỉ đơn giản gồm 5 lớp self-attention. nó trực tiếp nhận biết các đối tượng động từ representation fusion. Các motion mask được tạo ra bởi một MLP head nhẹ, lấy đầu ra của lớp cuối cùng encoder làm đầu vào
Các tham số của motion decoder được khởi tạo bằng trọng số pretrained của confidence decoder trong π^3. Toàn bộ framework đơn giản, gọn gàng và hoạt động theo cơ chế feed-forward end-to-end.
Do các biểu diễn đặc trưng có độ phân giải thấp hơn so với frame gốc, các motion mask thu được ban đầu là các mask thô. Trong giai đoạn kiểm thử, các motion mask được dự đoán được đưa vào mô hình phân đoạn thị giác SAM2 [33] để thu được các segmentation mask chi tiết, có độ phân giải cao cuối cùng. Thao tác này giống với bước tinh chỉnh cuối cùng được sử dụng trong RoMo

- *SAM2* sẽ cho biết chính xác biên của object đó nằm ở đâu.

4.2. Visual Geometry Backbone

Paper sử dụng *alternating attention* tiêu chuẩn từ VGGT và π^3 là Visual Geometry Backbone (VGB)
Tương tự như π^3, chúng tôi sử dụng **36 lớp alternating attention** để nhận biết và biểu diễn các **đặc trưng hình học 4D tiềm ẩn (latent 4D geometry features)**.

Các lớp nông (shallow layers), nằm gần với các đặc trưng đầu ra của DINO, có xu hướng nắm bắt các đặc trưng ở cấp độ hình ảnh (image-level features). Trong khi đó, các lớp sâu hơn (deeper layers), nhờ tích lũy dần các đặc trưng cấp cao qua từng lớp, có xu hướng nắm bắt các mẫu ngữ cảnh và cấu trúc phong phú hơn. Việc trực quan hóa các đặc trưng tại những lớp này được trình bày trong Hình 3.
Do đó, chúng tôi kết hợp cả đặc trưng từ các lớp nông và các lớp sâu để thu được các đặc trưng 4D tiềm ẩn mạnh mẽ và ổn định hơn.
Đặc trưng đầu ra (F_{geo}) được hình thành bằng cách nối (concatenation) các đặc trưng từ các lớp thứ 5, 15, 35 và 36, được lựa chọn dựa trên thực nghiệm.
Ngoài ra, đầu ra của hai lớp cuối cùng trong VGB được đưa vào camera pose decoder để tạo ra biểu diễn/ước lượng tư thế camera (F_{cam}).

4.3. Training loss

Mask decoder dự đoán một motion mask $M \in [0,1]^{H \times W}$ cho mỗi frame của video. Mask này biểu diễn xác suất mỗi pixel thuộc về một đối tượng đang chuyển động.

Hàm mục tiêu huấn luyện $\mathcal{L}$ kết hợp *Focal loss* và *Dice loss* trên một chuỗi gồm N frame:

$$\mathcal{L} = \sum_{t=1}^{N} \left[\lambda_1 \mathcal{L}_{\text{focal}}(M_t, M_t^{gt}) + \lambda_2 \mathcal{L}_{\text{dice}}(M_t, M_t^{gt}) \right].$$

trong đó:

- λ_1 và λ_2 được sử dụng để cân bằng mức đóng góp giữa từng thành phần loss
- Focal loss giúp mô hình tập trung nhiều vào pixel khó phân loại, từ đó cải thiện khả năng xử lý những đối tượng chuyển động nhỏ, không rõ ràng hoặc bị che khuất một phần
- Dice loss giúp giảm vấn đề về mất cân bằng giữa foreground và background bằng cách tối ưu trực tiếp mức độ chồng lấp không gian kết quả dự đoán và ground ttruth, Nhờ đó mô hình tạo ra dự đoán chuyển động ổn định hơn và liền mạch hơn

Focal loss

Focal loss được sử dụng để làm giảm ảnh hưởng của các pixel dễ phân loại cad tập trung quá trình học vào các pixel khó. Điều nay đặc biệt hữu ích trong motion segmentation, nơi phần lớn pixel thường thuộc background trong khi moving object chỉ chiếm một vùng nhỏ của ảnh,

$$\mathcal{L}_{\text{focal}} = -\alpha_t (1 - p_t)^{\gamma} \log(p_t)$$

Trong đó:

- p_t là xác suất mô hình gán cho ground-truth class , p là xác suất pixel thuộc moving object

$$p_t = \begin{cases} p, & y = 1, \\ 1 - p, & y = 0. \end{cases}$$

- α_t : được sử dụng để điều chỉnh mức đóng góp của các class. trong trường hợp số lượng background lớn hơn rất nhiều so với moving-object pixel, class moving có thể được gán trọng số tương đối lớn nhằm hạn chế việc quá trình tối ưu bị chi phối bởi background
- $(1 - p_t)^\gamma$: đóng vai trò điều chỉnh mức độ tập trung vào các mẫu khó. Khi mô hình dự đoán chính xác với $p_t \to 1$, thành phần này tiến về 0, làm giảm đáng kể loss của các pixel dễ. Ngược lại khi mô hình dự đoán sai hoặc không chắc chắn, thành phần này lớn khiến các pixel khó đóng góp nhiều hơn vào quá trình cập nhật mô hình
  Do đó , Focal Loss được hiểu là

$$\text{Classification Loss} \times \text{Class Weight} \times \text{Difficulty Weight}.$$

Dice Loss

Dice Loss trực tiếp đánh giá mức độ chồng lấp giữa vùng segmentation dự đoán và ground-truth mask

$$Dice(M; M^{gt}) = \frac{2 \sum_i M_i M_i^{gt} + \epsilon}{\sum_i M_i + \sum_i M_i^{gt} + \epsilon},$$

trong đó i duyệt qua các pixel và ϵ là một hằng số nhỏ đảm bảo ổn định số học
Dice Loss được xác định:

$$\mathcal{L}_{\text{Dice}} = 1 - Dice(M, M^{gt}).$$

Nếu predicted mask trùng hoàn toàn với ground truth:

$$Dice = 1 \quad \Rightarrow \quad \mathcal{L}_{\text{dice}} = 0.$$

Ngược lại, mức độ overlap càng thấp thì Dice Loss càng lớn.

Dice Loss đặc biệt phù hợp với motion segmentation do foreground và background thường mất cân bằng mạnh. Thay vì để số lượng lớn background pixels chi phối loss, Dice Loss trực tiếp tối ưu mức độ overlap của vùng moving object, giúp mô hình tạo ra các motion mask đầy đủ, ổn định và nhất quán hơn về mặt không gian.

5. Experiment

5.1. Experience setting

Training dataset	Loại	Quy mô được nêu	Điểm đáng chú ý	đặc điểm
HOI4D	Real	2.972 videos	Egocentric, human-object interaction	thu thập dưới góc nhìn thứ nhất. Sử dụng frame có chứa dynamic object mask
Dynamic Replica	Synthetic	584 videos	Camera + object motion	Được thiết kế cho tái tạo 3D, có tồn tại camera pose và object. Cung cấp annotation cho long term tracking và object mask
YTVOS18-m	Real/video segmentation	120 sequences	Dominant moving objects	Bộ dữ liệu video object segmentation, nó cung cấp nhiều chuỗi video được annotation cùng các dynamic mask
OmniWorld-motion	Game/synthetic	9 long sequences	2K–10K frames/video	Dataset chứa nhiều loại scene đa dạng với các chuỗi thời gian dài
GOT-Motion	Real	130 videos	Tracking data + motion mask annotation	Một bộ dữ liệu Object tracking thế giới thực có độ khó cao

Benchmark đánh giá

Để đánh giá, chúng tôi sử dụng năm benchmark motion segmentation phổ biến:

- DAVIS2016 [31]
- DAVIS2016-Moving [5]
- DAVIS2017 [32]
- SegTrack-v2 [18]
- FBMS-59 [29]

Set up

Mô hình được huấn luyện trong 15 epoch bằng optimizer Adam [16], với learning rate = 5×10^{-5}.
Quá trình training được thực hiện trên 4 GPU NVIDIA RTX 5090, mỗi GPU có 32 GB bộ nhớ.
Để thu thập nhiều pattern chuyển động khác nhau, khoảng cách lấy mẫu frame (frame sampling step) được điều chỉnh động dựa trên số frame trung bình của video trong từng dataset.

Trong quá trình training, mỗi batch chứa 16 frame.

Các frame được center-crop để duy trì tỷ lệ khung hình, sau đó được resize về độ phân giải 518×518.

Kết quả

Method	Iterative	DAVIS16-M J&F	J	F	DAVIS17 J	FBMS J	F	DAVIS16 J&F
OCLR-TTA	Yes	78.5	80.2	76.9	76.0	69.9	68.3	78.8
RoMo	Yes	–	–	–	–	75.5	–	–
SegAnyMotion	Yes	89.5	89.2	89.7	90.0	78.3	82.8	90.9
CIS	No	66.2	67.6	64.8	–	63.6	–	68.6
EM	No	75.2	76.2	74.3	55.5	57.9	56.0	70.0
RCF-Stage1	No	77.3	78.6	76.0	76.7	69.9	–	78.5
OCLR-flow	No	70.0	70.0	70.0	69.9	65.5	64.9	71.2
ABR	No	72.0	70.2	73.7	74.6	81.9	79.6	72.5
GeoMotion (Ours)	No	83.9	83.5	84.3	81.1	72.5	78.5	84.7

Metrix đánh giá là J - Region Similarity/ IoU

$$J = \frac{|M_{\text{pred}} \cap M_{\text{gt}}|}{|M_{\text{pred}} \cup M_{\text{gt}}|}$$

- Nó trả lời > Vùng object mà model segment ra overlap với vùng GT tốt đến đâu?

  Ví dụ:

  - GT có 100 pixels
  - Prediction có 80 pixels
  - Trong đó 70 pixels overlap.

  Intersection:

  $$|Pred \cap GT| = 70$$

  Union:

  $$|Pred \cup GT| = 100 + 80 - 70 = 110$$

  nên:

  $$J = \frac{70}{110} = 0.636$$

  hay:

  $$\boxed{J = 63.6\%}$$

  Càng gần 100% càng tốt.

F - Contour/boundary Similarity

F quan tâm đường biên của predicted mask có khớp GT không

- hai vùng có thể ovelap khá nhiều --> J cao
- Nhưng prediction bị phình ra --> boundary không chính xác --> F giảm

Về nguyên lý, nó tính boundary precision và boundary recall rồi kết hợp bằng F-measure:

$$\boxed{F = \frac{2P_{\text{boundary}}R_{\text{boundary}}}{P_{\text{boundary}} + R_{\text{boundary}}}}$$

Trong đó:

$$P_{\text{boundary}} = \frac{\text{predicted boundary khớp GT}}{\text{predicted boundary}}$$

và:

$$R_{\text{boundary}} = \frac{\text{GT boundary được prediction bắt được}}{\text{GT boundary}}$$

Nói ngắn:

$$\boxed{F = \text{biên object có chính xác không?}}$$

5.2. Comparison with motion Segmantation Methods

Phương pháp của chúng tôi được so sánh với các phương pháp tiêu biểu dựa trên tín hiệu chuyển động (motion cues), bao gồm CIS [50], EM [25], RCF [20], OCLR-flow [44] và ABR [46], cũng như các phương pháp dựa trên tối ưu lặp (iterative optimization), bao gồm OCLR-TTA [44], RoMo [7] và SegAnyMotion [11].
Phương pháp của chúng tôi được so sánh với các phương pháp tiêu biểu dựa trên tín hiệu chuyển động (motion cues), bao gồm CIS [50], EM [25], RCF [20], OCLR-flow [44] và ABR [46], cũng như các phương pháp dựa trên tối ưu lặp (iterative optimization), bao gồm OCLR-TTA [44], RoMo [7] và SegAnyMotion [11].
RoMo, CIS, EM và RCF là các phương pháp hoàn toàn không giám sát (fully unsupervised) và được huấn luyện trên các video không có nhãn.
ABR được pre-train trên dữ liệu tổng hợp, sau đó tiếp tục thích nghi với video thực theo phương pháp self-supervised.
SegAnyMotion dựa vào một lượng lớn dữ liệu motion segmentation được con người gán nhãn.

5.2.1.QuantitativeComparison

So sánh định lượng được trình bày trong Bảng 1. Kết quả cho thấy phương pháp được đề xuất đạt độ chính xác và tính ổn định cao trong segmentation trên nhiều benchmark, đồng thời vẫn duy trì hiệu quả tính toán cao.
Trong số các phương pháp hiệu quả không sử dụng iterative refinement, phương pháp của chúng tôi đạt kết quả tổng thể tốt nhất trên gần như tất cả các benchmark. Cụ thể, phương pháp đạt (J&F=83.9) trên DAVIS2016-M và (J&F=84.7) trên DAVIS2016, lần lượt vượt phương

pháp tốt thứ hai là RCF-Stage1 [20] 6.6 và 6.2 điểm. Sự cải thiện đáng kể này cho thấy thiết kế được đề xuất có hiệu quả trong việc khai thác đồng thời thông tin về appearance và motion nhằm thực hiện moving-object segmentation chính xác.
So với ABR [46], một phương pháp nhấn mạnh vào quá trình refinement dựa trên appearance, phương pháp được đề xuất thể hiện hiệu năng ổn định hơn trên nhiều dataset và metric, đặc biệt là đối với chỉ số (F). Điều này cho thấy khả năng xác định contour chính xác hơn và tính nhất quán theo thời gian tốt hơn.
Đáng chú ý, mô hình được đề xuất cũng vượt qua một số phương pháp dựa trên iterative optimization. Ví dụ, so với OCLR-TTA [44], phương pháp của chúng tôi đạt (J&F) cao hơn 5.4 điểm trên DAVIS2016-M. Ngay cả khi so sánh với SegAnyMotion [11], một phương pháp gần đây có năng lực lớn, phương pháp của chúng tôi vẫn đạt kết quả cạnh tranh trong khi yêu cầu chi phí tính toán thấp hơn đáng kể, qua đó xác nhận tính hiệu quả của kiến trúc được đề xuất.

Trên dataset FBMS-59, ABR đạt giá trị (J) cao nhất, 81.9, nhờ cơ chế refinement dựa trên appearance. Tuy nhiên, phương pháp của chúng tôi vẫn duy trì hiệu năng tương đối tốt với (J=72.5) và (F=78.5), cho thấy khả năng tổng quát hóa ổn định trên nhiều tình huống chuyển động khác nhau.

Trên dataset FBMS-59, ABR đạt giá trị (J) cao nhất, 81.9, nhờ cơ chế *refinement* dựa trên *appearance*. Tuy nhiên, phương pháp của chúng tôi vẫn duy trì hiệu năng tương đối tốt với (J=72.5) và (F=78.5), cho thấy khả năng tổng quát hóa ổn định trên nhiều tình huống chuyển động khác nhau.
Điều này mang lại lợi thế cho ABR trên FBMS-59, nơi các đối tượng có thể có chuyển động yếu và đường biên mask chủ yếu được xác định dựa trên các đặc trưng appearance nổi bật. Trong những trường hợp như vậy, mô hình dựa trên motion của chúng tôi đưa ra các dự đoán mang tính bảo thủ hơn, dẫn đến các mask không hoàn chỉnh. Việc SegAnyMotion [11] cũng có hiệu năng thấp tương tự trên benchmark này củng cố cho nhận định trên.
Ngoài ra, mô hình của chúng tôi đạt kết quả tốt nhất trên SegTrackV2, cho thấy khả năng xử lý mạnh mẽ đối với các chuỗi video có độ phân giải thấp và chuyển động phức tạp.

Thiết kế feed-forward cho phép thực hiện inference end-to-end, có khả năng tổng quát hóa tốt và giảm chi phí inference so với các phương pháp iterative. So sánh runtime được trình bày ở cột cuối của Bảng 1. Phương pháp của chúng tôi duy trì hiệu năng cao với tốc độ 0.31 giây/frame, gần với các baseline như ABR (0.28 giây/frame) và OCLR-flow (0.20 giây/frame).
Thiết kế feed-forward cho phép thực hiện inference end-to-end, có khả năng tổng quát hóa tốt và giảm chi phí inference so với các phương pháp iterative. So sánh runtime được trình bày ở cột cuối của Bảng 1. Phương pháp của chúng tôi duy trì hiệu năng cao với tốc độ 0.31 giây/frame, gần với các baseline như ABR (0.28 giây/frame) và OCLR-flow (0.20 giây/frame).

Nhìn chung, các kết quả so sánh xác nhận rằng phương pháp được đề xuất đạt được sự cân bằng tốt giữa chất lượng segmentation và hiệu quả tính toán. Những cải thiện nhất quán trên

nhiều dataset và metric cho thấy khả năng tổng quát hóa của mô hình đối với nhiều tình huống motion segmentation trong thế giới thực.

5.2.2. QuantitativeComparison

Hình 4 trình bày các so sánh định tính thông qua nhiều kết quả trực quan trên các dataset DAVIS2016-M, DAVIS2017 và SegTrackV2 [18].

So với các phương pháp hiện có như OCLR-Flow [44], SegAnyMotion [11] và RoMo [7], phương pháp được đề xuất tạo ra các motion mask vừa **hoàn chỉnh về mặt hình học (geometrically complete)** vừa **nhất quán về mặt thị giác (visually consistent)**.
Có thể nhận thấy OCLR-Flow thường gặp tình trạng các vùng segmentation bị phân mảnh và đường biên không chính xác do phụ thuộc vào các optical-flow cue cấp thấp. Trong khi đó, SegAnyMotion xuất hiện hiện tượng **over-segmentation** trong những scene phức tạp, đặc biệt khi background có chuyển động mạnh hoặc camera bị rung.
RoMo có xu hướng làm mất các chi tiết cấu trúc nhỏ khi vật thể có displacement lớn hoặc khi điều kiện chiếu sáng thay đổi, chẳng hạn trong các trường hợp con thiên nga và con tàu.
Ngược lại, phương pháp của chúng tôi có khả năng bảo toàn chính xác hình học của vật thể ngay cả trong những điều kiện khó như occlusion, chuyển động nhanh và background phức tạp.
Nhìn chung, những ưu điểm trực quan này cho thấy tính mạnh mẽ và độ tin cậy của thiết kế được đề xuất trên nhiều loại dynamic scene khác nhau.

5.3. Comparison with Reconstruction methods

Methods	Cam	Flow	Sh.	DAVIS2017		
				$\mathcal{J}\&\mathcal{F}\uparrow$	$\mathcal{J}\uparrow$	$\mathcal{F}\uparrow$
Baseline	✗	✗	✗	67.9	68.3	67.6
+ Cam	✓	✗	✗	74.2	74.2	74.3
+ Flow	✗	✓	✗	74.7	74.8	74.7
+ Shallow	✗	✗	✓	72.4	71.9	72.9
+ Cam + Shallow	✓	✗	✓	76.0	76.1	75.9
+ Flow + Shallow	✗	✓	✓	78.6	78.2	79.0
+ Cam + Flow	✓	✓	✗	80.2	80.2	80.2
All	✓	✓	✓	**81.4**	**81.1**	**81.8**

Training Datasets	#D.	DAVIS2016-M		DAVIS2017	
		$\mathcal{J}\uparrow$	$\mathcal{F}\uparrow$	$\mathcal{J}\uparrow$	$\mathcal{F}\uparrow$
+ HOI4D [22]	1	67.9	68.8	65.4	66.5
+ Dynamic Replica [14]	2	75.1	76.2	73.8	74.3
+ OmniWorld-motion	3	77.8	77.6	76.1	75.6
+ YTVOS18-m [46]	4	80.6	80.8	79.3	79.8
+ GOT-Motion	5	**83.5**	**84.3**	**81.1**	**81.8**

